

О. Ю. КОЛЛАРОВ, (канд. техн. наук, доц.), Д. О. ОСТРЕНКО**Державний вищий навчальний заклад****«Донецький національний технічний університет»****kollarov@gmail.com, dmytro.ostrenko@gmail.com**

АНАЛІЗ ЗАСТОСУВАННЯ ЗГОРТКОВИХ НЕЙРОННИХ МЕРЕЖ ДЛЯ ПІДВИЩЕННЯ НАДІЙНОСТІ У РОБОТІ ФЕС

Дана робота присвячена дослідженню застосування згорткових нейронних мереж (CNN) для автоматичного розпізнавання станів фотоелектричних панелей на основі зображень. Увага приділяється впливу налаштування гіперпараметрів CNN, таких як кількість шарів штучної нейронної мережі (ШНМ), розмір ядра згортки, швидкість навчання та функції активації, точність класифікації різних станів панелей, зокрема, фізичних пошкоджень, електричних дефектів, забруднення пилом.

Застосування CNN обумовлене їх здатністю автоматично виявляти складні просторові закономірності в зображеннях, що є важливим для точного розпізнавання різних типів дефектів та аномалій у фотоелектричних панелях (ФП). Основними викликами стали варіативність стану модулів і зовнішніх факторів, які впливають на якість даних. Було проаналізовано вплив гіперпараметрів CNN на якість класифікації та визначено їх оптимальні значення для досягнення високої точності моделі.

Актуальність дослідження полягає в зростаючій ролі CNN у системах моніторингу стану ФП, що дозволяє своєчасно виявляти дефекти та оптимізувати їх технічне обслуговування. Результати демонструють, що правильне налаштування гіперпараметрів CNN суттєво підвищує точність класифікації, що сприяє підвищенню ефективності та стабільності роботи фотоелектричних станцій в цілому.

Робота підкреслює важливість використання нейронних мереж для аналізу зображень у сфері технічного обслуговування фотоелектричних систем, що забезпечує їх ефективну інтеграцію в енергетичні мережі.

Ключові слова: згорткові нейронні мережі, прогнозування генерації, фотоелектричні станції, гіперпараметри, просторово-часові дані, енергетична ефективність, технічне обслуговування, сенсори, інвертор, варіативність погодних умов, енергетичний баланс, аналіз даних, оптимізація моделей, відновлювана енергія, енергетичні мережі.

Об'єкт дослідження – процес автоматичного розпізнавання станів фотоелектричних панелей за допомогою згорткових нейронних мереж (CNN) та вплив гіперпараметрів на точність класифікації дефектів.

Мета роботи – підвищення точності класифікації станів фотоелектричних панелей шляхом оптимізації моделей CNN для своєчасного виявлення дефектів і підвищення ефективності технічного обслуговування ФЕС.

Задачі дослідження: проведення математичного моделювання на основі згорткової нейронної мережі для класифікації станів фотоелектричних панелей (чисті панелі, фізичні пошкодження, забруднення, електричні дефекти). Дослідження впливу основних характеристик НМ (глибина мережі, розмір фільтрів, функція активації, кількість епох) на точність класифікації зображень панелей. Аналіз ефективності моделі при класифікації різних типів дефектів на панелях і вивчення залежності результатів від зовнішніх факторів (наприклад, варіацій освітлення). Порівняння результатів класифікації при зміні гіперпараметрів та побудова графіків залежності точності від їхніх значень. Оцінка ефективності запропонованої моделі CNN у порівнянні з іншими методами класифікації, такими як класичні алгоритми машинного навчання (SVM, Random Forest). Визначення оптимальних налаштувань гіперпараметрів для побудови моделей, що забезпечують найвищу точність класифікації станів фотоелектричних панелей на основі реальних даних.

Згорткові нейронні мережі найчастіше використовуються для обробки зображень, але їхня архітектура може бути адаптована для прогнозування робочих режимів фотогальванічних електростанцій, якщо структуру даних правильно підготувати.

Для адаптації CNN до аналізу режимів ФЕС можна розглянути кілька підходів [7-9]:

1. Перетворення вхідних даних у "зображення". Дані про робочі режими ФЕС можуть включати показники виробництва енергії, метеорологічні дані, електричні показники (значення напруги, струму). Такі дані можна організувати у вигляді матриці, де рядки і стовпці будуть представляти різні параметри чи часові інтервали. CNN може виявити просторові та часові взаємозв'язки між цими показниками.
2. Гібридні моделі. Можна поєднати CNN з іншими моделями для обробки табличних даних. Наприклад, згорткові шари можуть використовуватися для виявлення патернів у наборах даних, після чого ці патерни передаються до LSTM або GRU для обробки тимчасових залежностей в режимах ФЕС.
3. Аналіз тимчасових рядів. Згортки можна застосовувати до тимчасових рядів для виявлення трендів у режимах роботи ФЕС на основі історичних даних. Застосування CNN для вивчення циклічності і трендів у даних може поліпшити прогнози.

4. Попередня обробка даних. Для отримання ефективних результатів необхідно нормалізувати та масштабувати числові дані, а також структурувати їх у такий спосіб, щоб CNN могли ідентифікувати кореляції між параметрами [10].

Для аналізу режимів ФЕС можна використовувати кілька модифікацій CNN:

- I. Класична архітектура CNN. Прості згорткові нейронні мережі з декількома згортковими шарами, шаром максимального пулінгу та повно зв'язними шарами для остаточної класифікації або регресії.
- II. CNN (1d) – одновимірні CNN можуть використовуватися для обробки тимчасових рядів, що часто застосовується для прогнозу в режимах енергетичних систем.
- III. CNN (2d), якщо дані можуть бути перетворені у вигляді двовимірної матриці, як у випадку з кількома параметрами для кожного часово-просторового відрізка, 2D CNN можуть виявитися корисними.
- IV. CNN (3d) якщо робочі режими ФЕС мають декілька шарів даних, таких як просторові та часові показники одночасно, можна використовувати 3D CNN для аналізу об'ємних даних.

Стає можливим із [7, 9, 13] виділення наступних переваг від використання CNN для аналізу робочих режимів ФЕС:

- автоматичне виявлення патернів (типової ознаки або структури). CNN відмінно справляються з виявленням складних взаємозв'язків у даних, що може бути корисно для виявлення несподіваних аномалій у робочих режимах ФЕС;

- обробка великих обсягів даних. CNN ефективно працюють з великими наборами даних, особливо якщо потрібно обробляти величезну кількість метеорологічних та енергетичних параметрів одночасно;

- інваріантність до зсувів, CNN можуть бути стійкими до невеликих змін у даних (наприклад, зміни температури чи освітленості на ФЕС), що дозволяє робити більш точні прогнози в умовах природної варіативності даних.

- гнучкість та інтеграція, CNN можна поєднати із іншими моделями глибокого навчання або навіть класичними моделями машинного навчання [16], що дозволяє створювати складні гібридні моделі для точніших прогнозів.

Отже, застосування згорткових нейронних мереж для прогнозу робочих режимів ФЕС є перспективним підходом, особливо якщо дані можуть бути представлені у вигляді матриць або часових рядів. Головна перевага CNN полягає в їхній здатності автоматично знаходити складні патерни та взаємозв'язки в даних. Проте важливо підкреслити, що найкращі результати можуть бути досягнуті шляхом комбінування CNN із іншими моделями для аналізу часових рядів або обробки табличних даних [15-18].

Після проведення аналізу [17] визначено, що використання згорткових нейронних мереж (CNN) у поєднанні з довгою короткочасною пам'яттю (LSTM) і механізмом уваги значно покращує точність прогнозування обсягів генерації електроенергії на фотоелектричних станціях (ФЕС). Модель CNN-LSTM продемонструвала найкращі результати порівняно з іншими класичними та глибокими моделями машинного навчання, такими як GBT, SVM, ANN, DNN та LSTM, як за умов ясної, так і частково хмарної погоди [15-17].

Завдяки здатності CNN обробляти просторові залежності, LSTM – враховувати часові залежності, ця модель досягла найнижчих показників похибки (nRMSE, nMAE) і найвищого коефіцієнта детермінації (R^2), що свідчить про її високу точність і стабільність у прогнозуванні.

Таким чином, CNN-LSTM є перспективним підходом для побудови моделей прогнозування генерації електроенергії на основі складних даних, зокрема, для умов зі значною невизначеністю, таких як частково хмарна погода. Механізм уваги в цій моделі дозволяє ефективніше працювати з нелінійними даними, що робить її корисною для більш точної оцінки потенційного виробітку електроенергії на ФЕС, а також для оптимізації управління енергосистемою.

Аналіз [18] демонструє, як CNN у поєднанні з технікою переносу навчання можуть ефективно ідентифікувати дефекти у PV-модулях шляхом витягу ознак із візуальних даних. У роботі розроблено дві моделі — одна на основі CNN, яка навчалась безпосередньо на експериментальних даних, і друга, що використовувала перенос навчання з більшого набору даних. Модель переносу навчання досягла високої точності, до 96.6% після 50 епох. Перенос навчання показав значне підвищення точності, особливо при обмеженій кількості експериментальних даних. Тести з різною кількістю даних і епох показали, що модель переносу навчання зберігає високу продуктивність, особливо при менших наборах даних чи кількості епох. На завершення, перенос навчання виявився ефективною технікою для виявлення дефектів у фотоелектричних модулях, особливо у випадках, коли кількість даних є обмеженою або обчислювальні ресурси недостатні. Цей підхід суттєво підвищує точність моделі та рекомендується для покращення продуктивності у подібних випадках.

У випадку згорткової нейронної мережі (CNN), процес збору даних та навчання моделі також містить декілька важливих етапів, подібних до тих, що використовуються у машинному навчанні. Однак CNN спеціально призначені для роботи з візуальними даними, що робить їх ідеальними для розпізнавання образів та інших завдань обробки зображень (рис. 1).

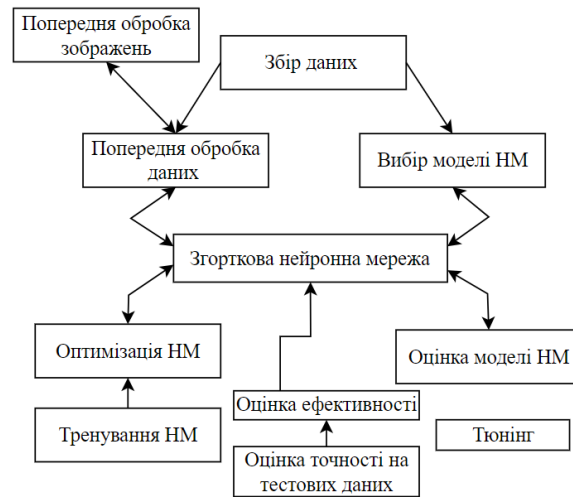


Рисунок 1 – Блок-схема алгоритму оптимізації для згорткової НМ у моделі ФЕС

Блок-схема процесу оптимізації CNN, показана на рис. 1, відображає етапи навчання та коригування моделі, що використовувалися в цій роботі. Процес застосування CNN для задач прогнозування у електричних мережах виглядає наступним чином:

1. Збір та попередня обробка даних. Як і у випадку з іншими алгоритмами, перший крок включає збір параметрів із різних джерел (сенсори, інвертори). Однак, у випадку CNN ці дані можуть включати зображення з камер або інші візуальні сигнали, що відображають стан електричного обладнання. Після цього проводиться очистка даних, нормалізація зображень та виділення корисних ознак, таких як форма, колір, інтенсивність.

2. Розділення даних на тренувальну та тестову вибірки. Важливо поділити зібрані дані на дві частини – тренувальну вибірку для навчання моделі та тестову для оцінки її продуктивності. У випадку CNN це можуть бути набори зображень, що відображають різні стани електрообладнання або дефекти.

3. Вибір архітектури CNN та її налаштування. Наступним кроком є обрання архітектури згорткової нейронної мережі. CNN складається з кількох шарів згортки та пулінгу, що дозволяє виділяти важливі ознаки зображень. Архітектура визначає кількість шарів, розмір фільтрів, тип функції активації та інші параметри.

4. Навчання моделі. CNN навчається на тренувальній вибірці зображень. Мережа проходить через кожне зображення, застосовуючи згорткові фільтри, які дозволяють витягувати ознаки (наприклад, контури, форми), та коригує ваги на основі результатів. Метою є мінімізувати похибку прогнозування через зворотне поширення помилки.

5. Оцінка продуктивності. Після навчання моделі, її продуктивність визначається на тестовій вибірці за допомогою метрик, таких як точність, Precision, Recall, F1-score. Для згорткових нейронних мереж також можуть бути використані специфічні метрики для зображень, такі як Intersection over Union (IoU).

6. Оптимізація моделі. Після первинного навчання можна провести оптимізацію моделі, змінюючи її гіперпараметри (кількість шарів, розмір фільтрів, тип регуляризації). Крім того, можна застосовувати такі техніки, як аугментація даних (наприклад, обертання зображень, зміна яскравості) для підвищення стійкості моделі.

7. Прогнозування. Використовуючи навчену CNN, можна прогнозувати обсяги генерації та виявляти помилки у нових даних, аналізуючи візуальні сигнали від сенсорів чи інверторів.



Рисунок 2 – Блок-схема алгоритму застосування CNN для прогнозування режимів ФЕС

Процес застосування CNN для прогнозування або класифікації також включає три основні етапи (рис. 2): попередня обробка зображень (складається із очистки і нормалізації, а також аугментації даних), навчання моделі прогнозування (вибір архітектури CNN та оптимізація гіперпараметрів) та оцінка точності на тестових зображеннях (оцінка вихідних метрик).

Згорткові нейронні мережі є потужним інструментом для аналізу складних даних, таких як зображення або часові ряди. Їх застосування виходить за межі класичних задач класифікації зображень і охоплює прогнози станів складних систем, таких як ФЕС. Використання CNN для аналізу режимів роботи ФЕС дозволяє не тільки передбачати ефективність генерації енергії, але й своєчасно виявляти аварійні або неефективні режими роботи обладнання. Завдяки CNN можна запобігти аваріям, підвищити ефективність експлуатації станцій та виявляти несправності ще до їх критичного розвитку. Метою навчання CNN є прогнозування аварійних режимів роботи ФЕС на основі історичних даних про погодні умови, рівні генерації енергії та інші технічні показники.

У практичній частині роботи розглянуто один із можливих підходів використання згорткових нейронних мереж (ШНМ) для забезпечення стабільної роботи фотоелектричних станцій (ФЕС) — а саме, ідентифікація ненормальних режимів роботи за аналізом зображень фотоелементів. Важливо відзначити, що цей підхід не є єдиним можливим. Згідно з проведеним аналізом, згорткові ШНМ можуть також застосовуватися для аналізу вихідних характеристик станцій, таких як струм, напруга або потужність. Якщо навчити модель на великому масиві даних, що включає як нормальні режими роботи, так і різні ненормальні стани (викликані як електричними, так і механічними пошкодженнями), ШНМ зможе ефективно класифікувати режими роботи ФЕС. Такий підхід може бути структурований аналогічно до використаного в цій роботі, з основною відмінністю у вхідних даних та спектрі аналізованих параметрів.

Таким чином, застосування згорткових нейронних мереж у цьому контексті є перспективним для широкого спектру задач моніторингу та діагностики ФЕС, що дозволяє підвищити надійність їх роботи та оперативність виявлення проблем.

Для класифікації зображень на різні категорії, такі як чисті, запилені, пошкоджені, було розроблено ШНМ із наступною архітектурою: використано кілька згорткових шарів (Conv2D) та шарів підвибірки (Pooling) для витягнення ключових ознак із зображень. Ці шари дозволяють моделі навчитися розпізнавати важливі візуальні патерни для кожної категорії.

Накопичення пилу на поверхні сонячних панелей знижує ефективність їх роботи, що, відповідно, призводить до зменшення виробленої енергії. В місцях розташування модулів ФЕС (як правило це відкритий простір цілий рік), де втрата потужності через пил є серед найвищих показників, моніторинг і очищення сонячних панелей стають критично важливими задачами. Розробка оптимальної процедури моніторингу та очищення цих панелей є надзвичайно важливою для підвищення їх ефективності, зменшення вартості обслуговування та скорочення використання ресурсів.

Що стосується навчання ШНМ на початковому наборі даних (dataset) й оцінки роботи моделі, то зображення розділено на три набори: тренувальний, валідаційний та тестовий. Що стосується кількісного розподілу даних, то для тренування використано 711 зображень, а для валідації — 174 зображення. Набір даних було створено за допомогою [10]. Дані було розподілено поміж 6 класами: Clean (ФП у нормальному стані), Bird (втручання у роботу панелей птахів), Dusty, Electrical_damage, Physical_Damage, Snow_Covered

Для навчання моделі налаштовано кількість епох (їх кількість було обрано 70, рис. 4) та розмір т.з. батчу НМ (обрано величину 64) для досягнення оптимальної продуктивності.

Далі за даними створено базову штучну згорткову НМ основні характеристики якої представлені на рис. 3. Вона складається з кількох шарів, які обробляють вхідні зображення розміром (150, 150, 3) через різні операції, такі як згортки (Convolution), пулінг (Pooling), згладжування (Flatten), і повнозв'язні шари (Dense).

Layer (type)	Output Shape	Param #	Layer (type)	Output Shape	Param #
conv2d_19 (Conv2D)	(None, 148, 148, 32)	896	conv2d_35 (Conv2D)	(None, 148, 148, 64)	1,792
max_pooling2d_19 (MaxPooling2D)	(None, 74, 74, 32)	0	max_pooling2d_35 (MaxPooling2D)	(None, 74, 74, 64)	0
conv2d_20 (Conv2D)	(None, 72, 72, 64)	18,496	conv2d_36 (Conv2D)	(None, 72, 72, 64)	36,928
max_pooling2d_20 (MaxPooling2D)	(None, 36, 36, 64)	0	max_pooling2d_36 (MaxPooling2D)	(None, 36, 36, 64)	0
conv2d_21 (Conv2D)	(None, 34, 34, 128)	73,856	conv2d_37 (Conv2D)	(None, 34, 34, 256)	147,712
max_pooling2d_21 (MaxPooling2D)	(None, 17, 17, 128)	0	max_pooling2d_37 (MaxPooling2D)	(None, 17, 17, 256)	0
conv2d_22 (Conv2D)	(None, 15, 15, 128)	147,584	conv2d_38 (Conv2D)	(None, 15, 15, 512)	1,180,160
max_pooling2d_22 (MaxPooling2D)	(None, 7, 7, 128)	0	max_pooling2d_38 (MaxPooling2D)	(None, 7, 7, 512)	0
flatten_7 (Flatten)	(None, 6272)	0	flatten_11 (Flatten)	(None, 25088)	0
dense_14 (Dense)	(None, 512)	3,211,776	dense_22 (Dense)	(None, 512)	12,845,568
dense_15 (Dense)	(None, 6)	3,078	dense_23 (Dense)	(None, 6)	3,078

Рисунок 3 – Створені початкова (базова) та оптимізована (за гіперпараметрами) штучні неромережі

При аналізі окремо характеристик кожного шару (всього їх 11 (рис. 3)) та ролі в архітектурі отримано:

1. Перший згортковий шар (Convolutional) з 64 фільтрами розміром 3x3, який застосовує фільтри для витягнення просторових ознак із зображення. Вхідний розмір зменшується до 148x148 через те, що використову-

ється фільтр 3x3 без padding.

2. Шар максимального пулінгу з ядром 2x2, який зменшує просторовий розмір вихідних даних на половину, залишаючи незмінну кількість фільтрів (64). Це зменшує розміри карти ознак і дозволяє моделі витягати найважливіші характеристики.
3. Згортковий шар з 64 фільтрами, розміром 3x3, який далі витягує ознаки з попереднього шару. Вихідний розмір зменшується до 72x72.
4. Шар максимального пулінгу, який зменшує розмір карти ознак до 36x36 і зберігає кількість фільтрів (64).
5. Згортковий шар з 256 фільтрами. Цей шар значно збільшує кількість фільтрів, що дозволяє витягати більш складні ознаки з вхідних даних.
6. Пулінговий шар, який зменшує розміри карти ознак до 17x17 і зберігає 256 фільтрів.
7. Останній згортковий шар з 512 фільтрами. Це найпотужніший шар, який витягує дуже детальні ознаки, необхідні для кінцевої класифікації.
8. Пулінговий шар, який зменшує просторовий розмір карти ознак до 7x7.
9. Шару згладжування (Flatten) перетворює 3d тензор (7x7x512) у вектор довжиною 25,088. Це необхідно для передачі даних у повнозв'язні шари (Dense).
10. Повнозв'язний шар з 512 нейронами, який виконує нелінійне перетворення ознак. Це один з основних шарів, який приймає рішення на основі витягнутих ознак.
11. Останній повнозв'язний шар з 6 нейронами. Він використовує функцію активації softmax, щоб виконати класифікацію на 6 класів.

Сама модель є глибокою згортковою нейронною мережею, яка поступово витягує ознаки на різних рівнях абстракції. Вона спочатку використовує кілька згорткових шарів для витягування простих та складних ознак зображення, потім ці ознаки передаються через повнозв'язні шари для кінцевої класифікації.

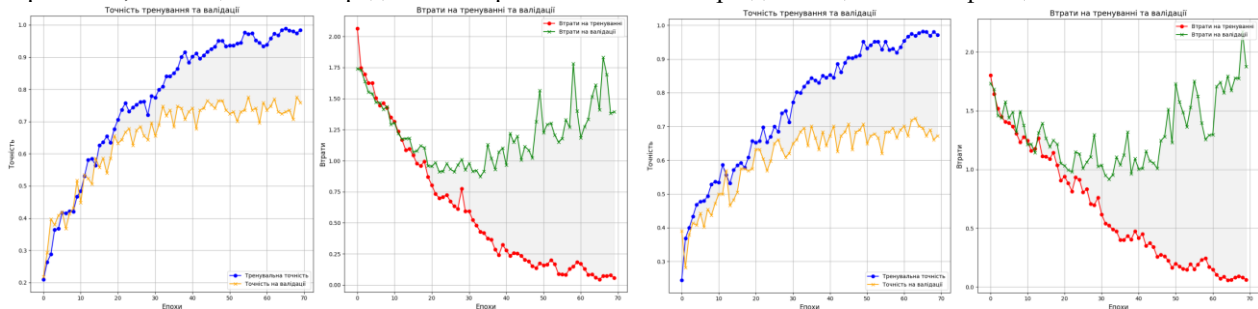


Рисунок 4 – Процес навчання базової та оптимізованої ШНМ

Щоб зробити візуалізацію результатів роботи НМ на випадкових зображеннях із набору даних, у середі Jupyter notebook (де і було створено дану НМ) є можливим скористатися генератором і вибрати певну кількість випадкових зображень, передбачити їхні класи та порівняти з реальними значеннями (рис. 5).



Рисунок 5 – Візуалізація роботи згорткової ШНМ

На основі отриманих результатів (рис. 6.1) показано, що під час навчання мережі точність як на тренувальних, так і на валідаційних даних поступово зростає з кожною епохою. Однак, на етапах валідації спостерігаються певні коливання, що може свідчити про ризик перенавчання моделі. Зокрема, крива точності на валідації демонструє нестабільність у порівнянні з тренувальною точністю, що може бути обумовлено варіативністю валідаційних даних або недостатньою кількістю тренувальних прикладів. З графіка втрат видно, що зменшення втрат відбувається поступово, проте, для валідаційних даних характерні різкі зміни, що вказує на можливі проблеми із узагальненням моделі.

Параметри архітектури CNN, такі як кількість шарів, суттєво впливають на здатність моделі виявляти складні просторові патерни. Додавання більшої кількості згорткових шарів, як зроблено в роботі, дозволяє поліпшити адаптацію до даних, але також може сприяти перенавчанню. Отримані результати підтверджують необхідність подальшого налаштування гіперпараметрів та застосування методів регуляризації, таких як Dropout або L2-регуляризація, для підвищення стабільності моделі під час валідації.

За аналізом впливу зміни кількості нейронів (рис. 6.2) у densely-шарах на точність нейронної мережі продемонстровано, що збільшення кількості нейронів сприяє підвищенню як тренувальної, так і валідаційної точності.

Як видно з графіків, тренувальна точність стабільно зростає протягом усіх епох, в той час як валідаційна точність має деякі коливання, але загалом демонструє позитивну динаміку. Втрати на тренуванні різко падають після першої епохи і надалі залишаються стабільними, а втрати на валідаційних даних мають схожу тенденцію, хоча в кінцевих етапах навчання залишаються дещо вищими. Така поведінка може бути пов'язана з недостатньою здатністю моделі узагальнювати знання на нових даних, що свідчить про необхідність подальшого налаштування гіперпараметрів або застосування методів регуляризації. Тому для підвищення точності, у майбутньому варто збільшити кількість прикладів для валідаційних даних. Це можливо досягнути, якщо накопичити, під час обслуговування ФЕС, більшу кількість прикладів (зображень) різних станів фотоелектричних модулів.




Рисунок 6 – Дослідження впливу зміни значень гіперпараметрів (1-кількість шарів в ШНМ, 2-кількість нейронів в шарах НМ) на точність класифікації згорткової ШНМ

Висновки. В даній роботі продемонстровано ефективність застосування згорткових нейронних мереж (CNN) для аналізу та прогнозування робочих режимів фотоелектричних станцій (ФЕС). Зокрема, досліджено, як коректна попередня обробка даних, оптимальне налаштування гіперпараметрів та використання CNN дозволяють суттєво підвищити точність класифікації та виявлення аномалій у роботі ФЕС.

Основними результатами дослідження стали:

- Розробка методів перетворення числових даних про робочі режими ФЕС у формат, придатний для аналізу за допомогою CNN.

- Аналіз впливу гіперпараметрів (глибини мережі, розміру фільтрів, функції активації) на точність моделі.

- Визначення найбільш ефективних архітектур CNN для різних форматів вхідних даних (1D, 2D, 3D).

В роботі продемонстровано здатність CNN автоматично виявляти складні патерни в робочих даних ФЕС, що дозволяє не тільки покращити прогнози вироблення енергії, але й ефективніше ідентифікувати технічні проблеми.

Застосування CNN, у поєднанні з іншими методами машинного навчання, дозволяє досягти високої точності прогнозування та забезпечити своєчасне виявлення дефектів фотоелектричних панелей, що значно сприяє підвищенню надійності та стабільності роботи фотоелектричних станцій. Результати роботи відкривають перспективи для подальшого вдосконалення методів моніторингу та оптимізації роботи ФЕС, а також розширюють можливості використання глибокого навчання в сфері ВДЕ.

СПИСОК ЛІТЕРАТУРИ

1. В. В. Литвин, Т. М. Басюк, Л. М. Захарія, Н.Е. Кунанець. "Машинне навчання": навч. посіб., м. Львів: видавництво «Новий Світ - 2000», 2019 р. - 335 с.
2. Згорткова нейронна мережа (CNN). Електронний ресурс: <https://www.tensorflow.org/tutorials/images/cnn> [дата звернення: 10.09.2024].
3. Базове пояснення згорткової нейронної мережі (CNN). Електронний ресурс: <https://www.kaggle.com/code/kanncaa1/convolutional-neural-network-cnn-tutorial> [дата звернення: 12.09.2024].
4. Колларов О. Ю. та Остренко Д. О. «Застосування методів класичного машинного навчання для прогнозування обсягів генерації електроенергії ФЕС», збірник «Наукові праці Донецького Національного Технічного Університету, серія: електротехніка і енергетика» №1(30)'2024, м. Луцьк, с 72-79.
5. Andreas C. Müller and Sarah Guido " Introduction to Machine Learning with Python A Guide for Data Scientists", Published by O'Reilly Media, Inc., 1005 Gravenstein Highway North, Sebastopol, 2017
6. Achmad Benny Mutiara, Evita Pramesti, Rina Refianti " Implementation of Deep Learning Using Convolutional Neural Network for Skin Disease Classification with DenseNet-201 Architecture ", 2023 Eighth International Conference on Informatics and Computing (ICIC), 2023, IEEE.
7. Як побудувати згорткову нейронну мережу на Python за допомогою Keras Електронний ресурс: <https://blog.mlq.ai/convolutional-neural-network-python-keras/> [дата звернення: 13.09.2024].

8. Колларов О. Ю., Остренко Д. О. «Генетичні алгоритми в задачах оптимізації роботи ФЕС», збірник «Наукові праці Донецького Національного Технічного Університету, серія: електротехніка і енергетика» №2(29)'2023, м. Луцьк, с 43-49.
9. Martin Sinko; Peter Sykora; Patrik Kamencay; Roberta Vrskova; Robert Hudec (2020). Comparison of convolutional neural network in Python environment on CPU and GPU. 2020 ELEKTRO. DOI: 10.1109/ELEKTRO49696.2020.9130321
10. Lior Kahana (2024). "Solar Panel dust detection (dataset)". Електронний ресурс: <https://www.kaggle.com/datasets/hemanthasai7/solar-panel-dust-detection> [дата звернення: 25.09.2024].
11. Neelashetty K., Durga Prasad Ananthu; (2021). A study of 100kWp PV Plant Output Power Forecasting: A case study 2021 5th International Conference on Computing Methodologies and Communication (ICCMC). 723-728pp
12. Usman Bashir Tayab; Kazi N. Hasan; Muhammad Faisal Hayat (2023). Short-term Industrial Demand Response Capability Forecasting using Hybrid EMD-AGTO-LSTM Model
13. Kazi N. Hasan; Usman Bashir Tayab; Muhammad Faisal Hayat (2023). GUI Energy Demand Forecast using LSTM Deep Learning Model in Python Platform DOI: 10.1109/ETFG55873.2023.10407702
14. Heyang Sun; Tong Li; Jinliang Song; Chao Yang; Zhenjiang Lei; Yang Liu; Yingli Zhang; Yihan Hou (2022). Research on Carbon Traceability of Power System Based on Blockchain and Power Flow Calculation under Carbon Peaking and Carbon Neutrality Goals. 2022 9th International Forum on Electrical Engineering and Automation (IFEAA). DOI: 10.1109/IFEAA57288.2022.10038246
15. Bo Jin; Fan Xia; Fei Long; Huan Xu; Shi Chen; Qingyao Zhao; Ziwei Mei; Xiaoyan Wei (2022). "Software Code Recognition Technology in Power Industry Based on Convolutional Neural Network". 2022 2022 International Conference on Artificial Intelligence of Things and Crowdsensing (AIoTC)
16. Xinxing Hou; Bo Wang; Chao Ju (2022). "Prediction of solar irradiance using convolutional neural network and attention mechanism-based long short-term memory network based on similar day analysis and an attention mechanism". 2022 International Conference on Artificial Intelligence of Things and Crowdsensing (AIoTCs) Електронний ресурс: <https://www.sciencedirect.com/science/article/pii/S2405844023086929> [дата звернення: 15.09.2024].
17. Sharmarke Hassan, Mahmoud Dhimish (2022). "Dual spin max pooling convolutional neural network for solar cell crack detection". Електронний ресурс: <https://www.nature.com/articles/s41598-023-38177-8> [дата звернення: 16.09.2024].
18. Lior Kahana (2024). "DPV module fault detection technique based on convolutional neural network". Електронний ресурс: <https://www.pv-magazine.com/2024/04/25/pv-module-fault-detection-technique-based-on-convolutional-neural-network/> [дата звернення: 16.09.2024].
19. Hamad Alharkan, Muhammad Islam Shabana and Habib "Solar Power Prediction Using Dual StreamCNN-LSTM Architecture". Sensors 2023,23, 945. <https://doi.org/10.3390/s23020945> Academic Editors: Songling Huang, Kai Song and Lisha Peng Електронний ресурс: https://www.researchgate.net/publication/367175069_Solar_Power_Prediction_Using_Dual_Stream_CNN-LSTM_Architecture [дата звернення: 17.09.2024].

REFERENCES

1. V. V. Lytvyn, T. M. Basyuk, L. M. Zakharia, N. E. Kunanets "Machine learning": training. manual, Lviv: "New World - 2000" publishing house, 2019 - 335 p.
2. Convolutional neural network (CNN). Electronic resource: <https://www.tensorflow.org/tutorials/images/cnn> [date accessed: 09/10/2024].
3. Basic explanation of Convolutional Neural Network (CNN). Electronic resource: <https://www.kaggle.com/code/kanncaa1/convolutional-neural-network-cnn-tutorial> [accessed 09/12/2024].
4. Kollarov O. and Ostrenko D. O. "Application of classical machine learning methods for forecasting the amount of electricity generation of FES", collection "Research works of Donetsk National Technical University, series: electrical engineering and energy" No. 1(30)'2024, Lutsk, pp. 72-79.
5. Andreas C. Müller and Sarah Guido "Introduction to Machine Learning with Python A Guide for Data Scientists", Published by O'Reilly Media, Inc., 1005 Gravenstein Highway North, Sebastopol, 2017
6. Achmad Benny Mutiara, Evita Pramesti, Rina Refianti "Implementation of Deep Learning Using Convolutional Neural Network for Skin Disease Classification with DenseNet-201 Architecture", 2023 Eighth International Conference on Informatics and Computing (ICIC), 2023, IEEE.

7. How to build a convolutional neural network in Python using Keras Electronic resource: <https://blog.mlq.ai/convolutional-neural-network-python-keras/> [access date: 2024-09-13].
8. Kollarov O. Yu., Ostrenko D. O. "Genetic algorithms in the tasks of optimizing the operation of the FES", collection "Scientific works of the Donetsk National Technical University, series: electrical engineering and energy" No. 2(29)'2023, Luts'k, pp. 43-49.
9. Martin Sinko; Peter Sykora; Patrik Kamencay; Roberta Vrskova; Robert Hudec (2020). Comparison of convolutional neural network in Python environment on CPU and GPU. 2020 ELEKTRO. DOI: 10.1109/ELEKTRO49696.2020.9130321
10. Lior Kahana (2024). "Solar Panel dust detection (dataset)". Електронний ресурс: <https://www.kaggle.com/datasets/hemanthsai7/solar-panel-dust-detection> [дата звернення: 25.09.2024].
11. Neelashetty K., Durga Prasad Ananthu; (2021). A study of 100kWp PV Plant Output Power Forecasting: A case study 2021 5th International Conference on Computing Methodologies and Communication (ICCMC). 723-728pp
12. Usman Bashir Tayab; Kazi N. Hasan; Muhammad Faisal Hayat (2023). Short-term Industrial Demand Response Capability Forecasting using Hybrid EMD-AGTO-LSTM Model
13. Kazi N. Hasan; Usman Bashir Tayab; Muhammad Faisal Hayat (2023). GUI Energy Demand Forecast using LSTM Deep Learning Model in Python Platform DOI: 10.1109/ETFG55873.2023.10407702
14. Heyang Sun; Tong Li; Jinliang Song; Chao Yang; Zhenjiang Lei; Yang Liu; Yingli Zhang; Yihan Hou (2022). Research on Carbon Traceability of Power System Based on Blockchain and Power Flow Calculation under Carbon Peaking and Carbon Neutrality Goals. 2022 9th International Forum on Electrical Engineering and Automation (IFEEA). DOI: 10.1109/IFEEA57288.2022.10038246
15. Bo Jin; Fan Xia; Fei Long; Huan Xu; Shi Chen; Qingyao Zhao; Ziwei Mei; Xiaoyan Wei (2022). "Software Code Recognition Technology in Power Industry Based on Convolutional Neural Network". 2022 International Conference on Artificial Intelligence of Things and Crowdsensing (AIoTC)
16. Xinxing Hou; Bo Wang; Chao Ju (2022). "Prediction of solar irradiance using convolutional neural network and attention mechanism-based long short-term memory network based on similar day analysis and an attention mechanism". 2022 International Conference on Artificial Intelligence of Things and Crowdsensing (AIoTCs) Electronic resource: <https://www.sciencedirect.com/science/article/pii/S2405844023086929> [access date: 15.09.2024].
17. Sharmarke Hassan, Mahmoud Dhimish (2022). "Dual spin max pooling convolutional neural network for solar cell crack detection". Electronic resource: <https://www.nature.com/articles/s41598-023-38177-8> [access date: 09/16/2024].
18. Lior Kahana (2024). "DPV module fault detection technique based on convolutional neural network". Electronic resource: <https://www.pv-magazine.com/2024/04/25/pv-module-fault-detection-technique-based-on-convolutional-neural-network/> [date of access: 16.09.2024].
19. Hamad Alharkan, Muhammad Islam Shabana and Habib "Solar Power Prediction Using Dual StreamCNN-LSTM Architecture". Sensors 2023,23, 945.<https://doi.org/10.3390/s23020945> Academic Editors: Songling Huang, Kai Song and Lisha Peng Electronic resource: https://www.researchgate.net/publication/367175069_Solar_Power_Prediction_Using_Dual_Stream_CNN-LSTM_Architecture [accessed on: 09/17/2024].

O. KOLLAROV, D. OSTRENKO.

State Institution of Higher Education «Donetsk National Technical University»

Analysis of the stagnation of the humeral neural networks for the advancement of reliable operation of a photovoltaic station. This work is dedicated to the study of applying convolutional neural networks (CNN) for automatic recognition of photovoltaic panel conditions based on images. The focus is placed on the impact of CNN hyperparameter tuning, such as the number of layers, kernel size, learning rate, and activation function, on the accuracy of classifying various panel conditions, including physical damage, electrical defects, dust contamination, and clean panels. The use of CNNs is driven by their ability to automatically detect complex spatial patterns in images, which is crucial for accurately identifying different types of defects and anomalies on the panels. The main challenges include the variability in panel conditions and external factors, such as weather conditions, that affect data quality. The influence of CNN hyperparameters on classification accuracy was analyzed, and their optimal values were determined to achieve high model accuracy. The relevance of the research lies in the growing role of CNNs in monitoring photovoltaic panel conditions, which enables timely defect detection and optimization of maintenance. The results demonstrate that proper hyperparameter tuning of CNNs significantly improves classification accuracy, contributing to increased efficiency and stability of photovoltaic stations. The paper emphasizes the importance of using neural networks for image analysis in

the field of photovoltaic system maintenance, ensuring their effective integration into energy networks. The goal of the study is to improve the accuracy of photovoltaic panel condition classification by developing and tuning CNN models with optimal hyperparameters, enabling timely detection of panel defects and enhancing the efficiency of photovoltaic system maintenance.

Keywords: *convolutional neural networks, generation forecasting, photovoltaic power plants, hyperparameters, spatiotemporal data, energy efficiency, maintenance, sensors, inverter, weather variability, energy balance, data analysis, model optimization, renewable energy, power grids.*